BÁO CÁO TIẾN ĐỘ

Bộ dữ liệu song ngữ Trung Việt cho thương mại điện tử

Từ dữ liệu crawl thô của 1688 và Tiki đến bộ chính thức

26.038
sản phẩm trong bộ chính thức

2
nguồn: 1688 và Tiki

9
nhóm hàng

2
mô hình dịch: Gemma và Qwen

Tháng 10/2026

Dữ liệu thô từ hai sàn

1688 Gốc tiếng Trung, cần dịch sang Việt

16.348 sản phẩm, 9 nhóm hàng

Trung (gốc)
牛奶洗面奶深层清洁补水保湿男女洁面乳

Việt (dịch)
Sữa rửa mặt sữa tươi làm sạch sâu cung cấp nước dưỡng ẩm cho nam nữ

Mô tả
化妆品功效: 补水保湿; 成分: 甘油
Công dụng mỹ phẩm: Cấp nước, dưỡng ẩm; Thành phần: Glycerin

Tiki Gốc tiếng Việt, cần dịch sang Trung

13.200 sản phẩm, 6 nhóm hàng

Việt (gốc)
Bánh mì hoa cúc Mini Harrys 210gr PHÁP

Trung (dịch)
迷你雏菊面包 Harrys 210克 法式

Mô tả
Thương hiệu: Harrys; Xuất xứ thương hiệu: Pháp
品牌: Harrys; 品牌产地: 法国

Mỗi sản phẩm gồm tiêu đề (Title) và mô tả (Description, là danh sách thuộc tính)

Phễu xử lý từ thô đến chính thức

Hai phần chạy song song: Description (Nhật Anh) và Title (Huy)

29.548	494.575	2	29.529	26.038
sản phẩm thô	cặp thuộc tính	mô hình dịch	sản phẩm có mô tả dịch	sản phẩm chính thức
Thu thập thô	**Làm sạch**	**Dịch từng cặp**	**Dịch theo cả cụm**	**Gộp và lọc**
1688: 16.348 Tiki: 13.200	Tách mô tả thành cặp, sửa bằng từ điển, bỏ thông tin riêng tư	Gemma 4 làm chính, Qwen3-14B dự phòng, CometKiwi chấm điểm	Hiệu đính cả danh sách thuộc tính theo ngữ cảnh sản phẩm	Loại 3.510 sản phẩm theo 6 quy tắc

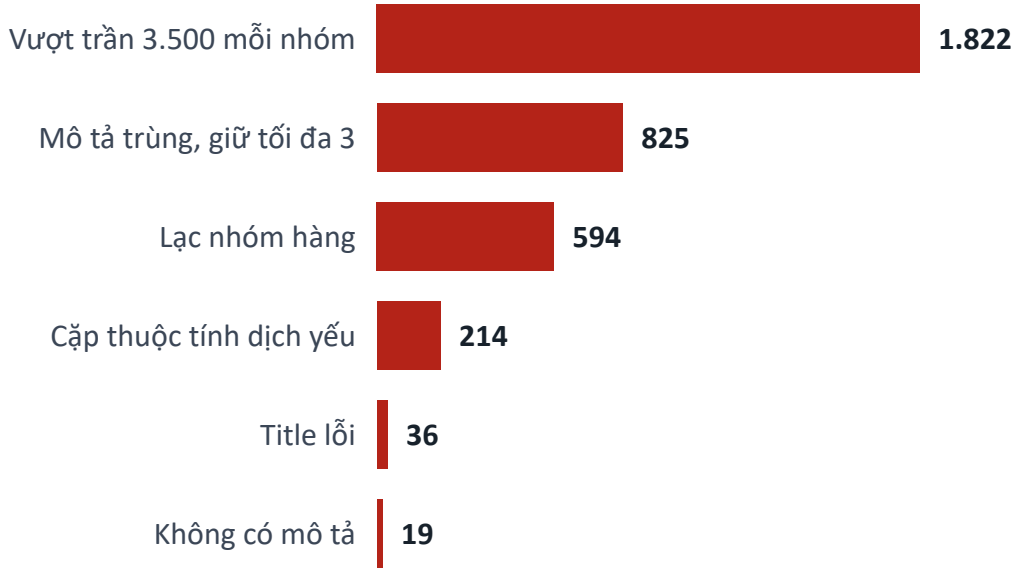
Title (Huy): dịch bằng 2 mô hình, chọn bản tốt hơn theo điểm COMETKiwi, sửa chữ Hán còn sót

Bước gộp cuối: loại 3.510 sản phẩm

29.548
sản phẩm vào bước gộp

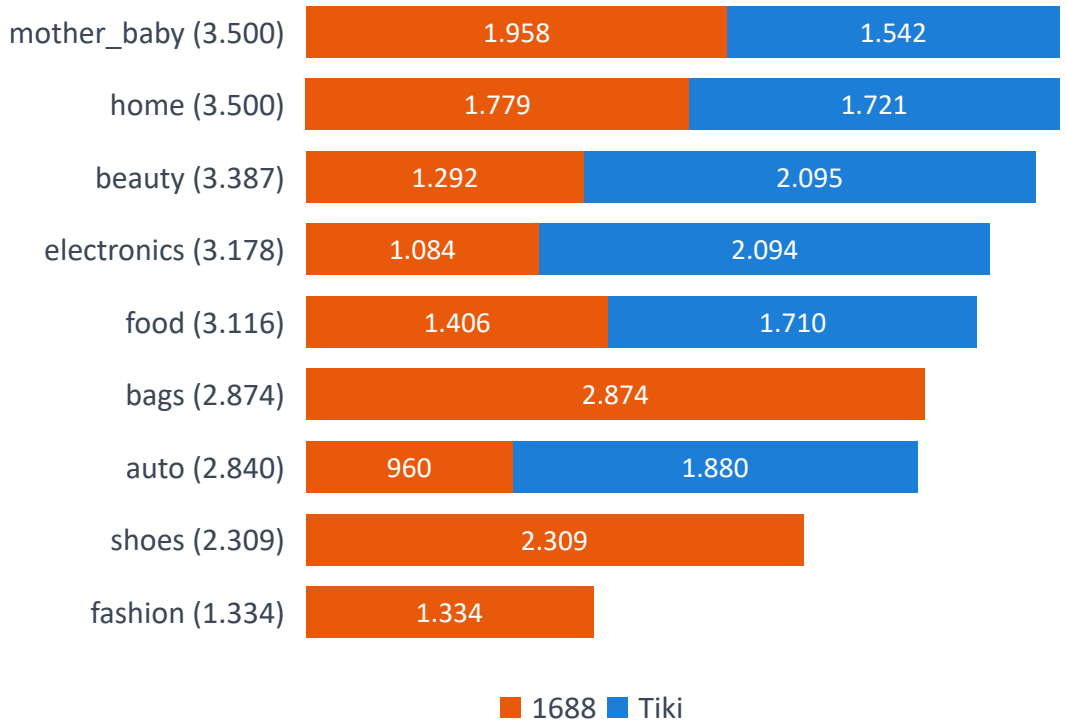
3.510
bị loại, chiếm 11,9%

26.038
sản phẩm giữ lại



Mỗi sản phẩm chỉ ghi một lý do: quy tắc đầu tiên nó vi phạm. Danh sách loại được lưu riêng, không xóa dòng nào ở file nguồn.

Cân bằng 9 nhóm hàng



Lớn nhất so với nhỏ nhất

3,5 lần

trước khi cân bằng

2,6 lần

sau khi cân bằng

bags, shoes, fashion chỉ có sản phẩm từ 1688

Hạn chế và việc tiếp theo

Cần lưu ý

1. Bản dịch do máy, mới kiểm theo mẫu, chưa có người rà toàn bộ
2. Title trùng nhau: 1688 có 757 sản phẩm thuộc 337 title lặp, Tiki có 153 sản phẩm thuộc 73 title
3. Túi, giày, thời trang chỉ có từ 1688; thời trang còn 1.334 sản phẩm

Việc tiếp theo (dự kiến)

1. Gom nhóm các title trùng rồi mới chia train, dev, test
2. Chọn tập test và nhờ người dịch rà soát
3. Cả nhóm chốt mô hình để huấn luyện

Dự phòng: 6 quy tắc loại sản phẩm

Quy tắc	Loại khi	Số loại
R0 Không có mô tả	Sản phẩm không có mô tả để dịch	**19**
R1 Lạc nhóm hàng	Thuộc 56 danh mục không hợp nhóm, ví dụ phụ kiện bể cá nằm trong nhóm food	**594**
R2 Cặp dịch yếu	Từ 25% số cặp thuộc tính trở lên có độ tin cậy thấp	**214**
R3 Mô tả trùng	Cùng nguồn và nhóm có hơn 3 mô tả giống hệt, chỉ giữ tối đa 3	**825**
R4 Title lỗi	Title còn chữ Hán, chưa dịch hoặc mô hình từ chối dịch	**36**
R5 Vượt trần nhóm	Nhóm quá 3.500 sản phẩm: bỏ bớt, ưu tiên danh mục kém hợp rồi sản phẩm có nhiều cặp yếu hơn	**1.822**
Tổng		**3.510**

Quy tắc áp theo thứ tự R0 đến R5; mỗi sản phẩm bị ghi theo quy tắc đầu tiên nó vi phạm.